

BÁO CÁO GPU FINOPS LAB

Họ và tên: Nguyễn Văn Thạch MSSV: 2A202600237

Môn/Lab: GPU FinOps & Cost Optimization

Notebook: Nguyễn Văn Thạch_GPU_FinOps_Submission/notebook/gpu_finops_lab.ipynb

1. Giới thiệu

Mục tiêu của bài lab

Bài lab này nhằm mô phỏng và phân tích toàn bộ vòng đời quản trị chi phí GPU cho workload AI/ML. Mục tiêu chính không chỉ là chạy workload trên GPU, mà còn quan sát được mức sử dụng tài nguyên, ghi nhận chi phí, phân tích phần lãng phí, đánh giá hiệu quả của spot instance, autoscaling, mixed precision và các chiến lược tối ưu chi phí nâng cao.

Thông qua bài lab, người học tiếp cận tư duy FinOps theo hướng thực hành: theo dõi mức tiêu thụ tài nguyên theo thời gian thực, gắn chi phí vào workload, phát hiện waste, so sánh các cấu hình khác nhau và đề xuất phương án tối ưu phù hợp với ràng buộc về ngân sách, hiệu năng và độ rủi ro.

Tổng quan về GPU FinOps

GPU FinOps là tập hợp các phương pháp giúp tối ưu chi phí sử dụng GPU trong các hệ thống AI/ML. Khác với CPU truyền thống, GPU có đơn giá cao, mức tiêu thụ điện lớn và hiệu quả chi phí phụ thuộc mạnh vào cách sử dụng workload. Một GPU nhàn rỗi hoặc dùng sai loại workload có thể gây lãng phí đáng kể. Vì vậy, GPU FinOps tập trung vào bốn vấn đề chính:

- Quan sát mức sử dụng GPU theo thời gian thực.
- Gắn chi phí vào từng workload và từng loại GPU.
- Tận dụng các cơ chế tiết kiệm như spot instance, autoscaling, scheduling.
- Tối ưu cấu hình huấn luyện như số lượng GPU, mixed precision, batch size, early stopping.

Trong bài lab này, các nguyên tắc trên được thể hiện qua cả hai môi trường: mock cluster để mô phỏng hệ thống phân tán, và real GPU để đo chi phí huấn luyện thực tế.

2. Phân tích từng phần

Part 1-7: Phân tích kết quả từ mock cluster

2.1. Cluster monitoring insights

Kết quả từ notebook cho thấy cluster tại thời điểm quan sát có 7 nodes, tương ứng 14 GPUs, trong đó có nhiều loại GPU khác nhau như T4, A100, V100. Ở thời điểm đo, hệ thống có:

Chỉ số	Giá trị
Busy GPUs	9
Idle GPUs	5
Average utilization	50,6%

Total memory used	193,0 GB / 384,0 GB
Total power draw	1 166 W

Sau khi submit thêm workload, hệ thống chuyển sang trạng thái 14/14 GPUs bận với average utilization 78,8%. Điều này chứng minh việc nạp workload đã tận dụng được phần tài nguyên nhàn rỗi, làm tăng hiệu quả khai thác cluster và là điều kiện phù hợp để kích hoạt autoscaling.

2.2. Cost tracking observations

Notebook đã ghi nhận chi phí cho bốn workload tiêu biểu:

Workload	Loại	Chi phí	Tiết kiệm
train-resnet-001	On-demand	\$0,0292	—
train-bert-002	On-demand	\$0,6117	—
inference-api-003	Spot	\$0,0035	\$0,0082
train-llm-004	Spot	\$0,5505	\$1,2845

Tổng hợp dự án	
Total cost	\$3,9229
Total savings	\$4,1229
Budget utilization	3,9% (ngân sách \$100)
Alert status	OK

2.3. Spot instance savings analysis

Giá spot quan sát được cho thấy mức giảm khá mạnh so với on-demand:

GPU	Giá Spot	Giá On-demand	Tiết kiệm
T4	\$0,2718	\$0,35	~22%
A100	\$2,0816	\$3,67	~43%
V100	\$1,8681	\$2,48	~25%

Ba yêu cầu spot đều được cấp phát thành công. Kết quả mô phỏng preemption: 0 preempted instances, Spot cost: \$0,0425, On-demand equivalent: \$0,1416, Total saved: \$0,0991 (70,0%). Spot instance là giải pháp rất hiệu quả cho workload có khả năng chịu gián đoạn.

2.4. Autoscaling behavior

Policy autoscaling đã được điều chỉnh theo hướng nhạy hơn:

- scale_up_threshold: 70%
- scale_down_threshold: 25%
- cooldown_seconds: 30
- max_nodes: 10

- min_nodes: 2

Khi hệ thống đạt 78,8% utilization, autoscaler quyết định scale_up: 7 → 8 nodes. Trong 5 chu kỳ tiếp theo, hành động đều là no_action với utilization ~68,9%. Cơ chế autoscaling hoạt động đúng logic: scale đúng lúc, không scale liên tục gây lãng phí.

2.5. Waste analysis và recommendations

Cost snapshot cho thấy hệ thống khá hiệu quả:

Chỉ số	Giá trị
Average waste	4,4%
Total idle cost	\$0,019440
Total cost	\$0,440830
Potential monthly savings	\$503,88
Severity	LOW

Đề xuất tối ưu: (1) Use spot instances – tiết kiệm ~65%; (2) Scheduling workload không khẩn cấp sang khung giờ giá spot thấp hơn – tiết kiệm ~20%.

2.6. Full FinOps workflow

Phản workflow tổng hợp mô phỏng một chu trình FinOps khép kín:

- Kiểm tra cluster ban đầu: 16 GPUs, utilization 68,9%
- Submit heavy workloads → utilization tăng lên 78,7%
- Autoscaler quyết định scale_up
- Waste tại thời điểm đó: 4,1%
- Áp dụng spot instance → savings 70,0%

Final billing: Total spend: \$4,0920 | Total saved: \$4,2453 | Budget used: 4,1%

Part 8: Phân tích real GPU training

2.7. Real GPU environment

Notebook đã nhận diện thành công GPU thực tế:

GPU	Tesla T4
Memory	15,6 GB
CUDA	12.8
Compute capability	sm_75

2.8. FP32 vs Mixed Precision (AMP) comparison

Chỉ số	FP32	AMP	Cải thiện
Total time	131,5s	61,4s	2,14x nhanh hơn
Peak memory	0,82 GB	0,60 GB	↓ 0,22 GB
Avg GPU utilization	94,4%	88,6%	—
Avg power	66,3 W	65,5 W	—
Estimated cost	\$0,012788	\$0,005971	↓ 53,3%

Kết quả rất rõ ràng: AMP vừa tăng tốc độ huấn luyện, vừa giảm chi phí, lại còn giảm memory footprint. Tiết kiệm lũy kế:

- 1 ngày training: tiết kiệm \$4,48
- 1 tuần training: tiết kiệm \$31,35
- 1 tháng training: tiết kiệm \$134,34

2.9. Cost savings achieved

Tổng hợp project real-gpu-lab: Total cost: \$0,0292 | Total savings: \$0,0084 | Workloads: 4. Khi kết hợp AMP với spot pricing, hiệu quả tiết kiệm trở nên cộng hưởng.

2.10. GPU utilization patterns

FP32 đạt mức sử dụng GPU trung bình rất cao (94,4%) và AMP vẫn duy trì utilization tốt (88,6%). Mức công suất trung bình gần như tương đương: FP32 66,3 W vs AMP 65,5 W. Kết luận quan trọng: AMP giảm chi phí chủ yếu nhờ giảm thời gian huấn luyện và memory footprint — "làm xong việc nhanh hơn".

Part 8.5: Advanced analysis

2.11. Multi-GPU scaling efficiency

Phân tích multi-GPU trên T4 với baseline 2 giờ:

GPU count	Speedup	Efficiency	Time (h)	Cost (USD)
1	1,0x	100%	2,000	\$0,7000

2	1,8x	90%	1,111	\$0,7778
4	3,2x	80%	0,625	\$0,8750
8	5,6x	70%	0,357	\$1,0000

Hiện tượng sub-linear scaling rất rõ: tăng GPU giảm thời gian nhưng chi phí tuyệt đối tăng, hiệu suất giảm từ 100% xuống 70%. Cấu hình tối ưu phụ thuộc mục tiêu kinh doanh (chi phí, deadline, hay cân bằng).

2.12. Project cost forecasting

Kịch bản	Chi phí
Expected (with contingency)	\$4 261,44
Best case	\$2 578,82
Worst case	\$5 233,82
95% confidence interval	\$3 573,51 – \$4 949,37

Phase tốn chi phí lớn nhất: Model Training (\$1 761,6) và Hyperparameter Tuning (\$1 761,6). Worst case vượt \$5 000 → cần buffer và chiến lược tài nguyên rõ ràng.

2.13. Optimization strategy prioritization

Phân tích chiến lược tối ưu cho baseline cost \$1 468,00:

Chiến lược	Savings	Tiết kiệm	Priority
Switch to Mixed Precision (AMP)	25%	\$367,0	Quick win
Use Spot Instances	60%	\$880,8	Strategic
Optimize Batch Size	15%	\$220,2	Quick win
Implement Early Stopping	20%	\$293,6	Next
Switch to Efficient GPU Type	40%	\$587,2	Strategic

Kết hợp toàn bộ: chi phí còn lại ~\$179,68, tiết kiệm \$1 288,32 (87,76%). Nên ưu tiên "quick win" trước (AMP, batch size) do effort thấp, risk thấp.

2.14. Challenge strategy – Fine-tuning LLM

Baseline: 8x A100, 200 giờ, cost \$5 872,00 | Budget: \$5 000 | Deadline: 2 tuần

Đề xuất: Giảm từ 8 GPU xuống 6 GPU, estimated training time 244h, cost trước optimization: \$5 373,07.

Kết hợp ba chiến lược rủi ro thấp/trung bình: AMP + Optimize Batch Size + Early Stopping:

Kết quả	Giá trị
Projected optimized spend	\$2 740,27
Planning range	\$1 644,16 – \$3 288,32

Under budget	True
Meets deadline	True

3. Kết luận và học hỏi

Những kỹ năng FinOps đã học

- Theo dõi utilization, memory, power và temperature của GPU.
- Gắn chi phí trực tiếp vào workload và từng loại GPU.
- So sánh on-demand và spot pricing để đánh giá savings.
- Điều chỉnh autoscaling policy để phản ứng phù hợp với tải hệ thống.
- Đánh giá waste và đọc optimization recommendations.
- So sánh hiệu quả runtime giữa FP32 và AMP trên GPU thực.
- Phân tích trade-off giữa tốc độ, chi phí và độ rủi ro trong bài toán multi-GPU.

Các chiến lược cost optimization hiệu quả

- Mixed Precision (AMP): hiệu quả rõ trên cả thời gian, memory và chi phí.
- Spot Instances: phù hợp cho workload chịu lỗi tốt, savings rất cao.
- Autoscaling: tránh overprovisioning khi tải thay đổi theo thời gian.
- Batch size tuning và early stopping: tác động trực tiếp đến chi phí hạ tầng.
- Lựa chọn số GPU hợp lý: không phải càng nhiều GPU càng hiệu quả về cost.

Ứng dụng thực tế trong projects

- Giảm chi phí huấn luyện mô hình trên cloud.
- Tăng hiệu quả sử dụng cluster GPU nội bộ.
- Lập kế hoạch ngân sách chính xác hơn trước khi triển khai training quy mô lớn.
- Xây dựng policy chọn loại instance và cấu hình training theo mức ưu tiên của dự án.

Tóm lại, bài lab cho thấy GPU FinOps không chỉ là bài toán theo dõi chi phí, mà là quá trình ra quyết định kỹ thuật dựa trên dữ liệu. Khi kết hợp monitoring, billing, autoscaling, spot usage và training optimization, có thể đạt được mức tiết kiệm rất lớn mà vẫn giữ được hiệu năng và tiến độ của dự án.